



Universidade Federal do Ceará

Disciplina: Processamento Estatístico de Sinais

Professor: Charles Casimiro Cavalcante

Estudante: Rubem Vasceconcelos Pacelli Matrícula: 474725

Novembro de 2019

Lista 4

1. A Função de correlação do sinal de entrada é

$$\begin{aligned}\mathbf{R}_x &= \begin{bmatrix} R_x(0) & R_x(1) \\ R_x(-1) & R_x(0) \end{bmatrix} \\ &= \begin{bmatrix} E[x^2[n]] & E[x[n]x[n-1]] \\ E[x[n-1]x[n]] & E[x^2[n-1]] \end{bmatrix} \\ \mathbf{R}_x &= \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}\end{aligned}\quad (1)$$

A Função de correlação cruzada entre o sinal de entrada e o sinal desejado é

$$\begin{aligned}\mathbf{R}_{dx} &= \begin{bmatrix} R_{dx}(0) \\ R_{dx}(-1) \end{bmatrix} \\ &= \begin{bmatrix} E[x[n]d[n]] \\ E[x[n-1]d[n]] \end{bmatrix} \\ \mathbf{R}_{dx} &= \begin{bmatrix} 0.5 \\ 0.25 \end{bmatrix}\end{aligned}\quad (2)$$

(a)

$$\begin{aligned}\mathbf{R}_x^{-1} &= \frac{1}{\det(\mathbf{R}_x)} \cdot \text{Adj}(\mathbf{R}_x) \\ \mathbf{R}_x^{-1} &= \begin{bmatrix} 1.33 & -0.67 \\ .67 & 1.33 \end{bmatrix}\end{aligned}\quad (3)$$

A equação de Wiener-Hopf fornece os coeficientes do filtro ótimo. Para as matrizes dadas nas equações (2) e (3), os parâmetros do filtro FIR é dado por [1]

$$\begin{aligned}\mathbf{w}_o &= \mathbf{R}_x^{-1} \mathbf{R}_{dx} \\ \mathbf{w}_o &= \begin{bmatrix} 0.5 \\ 0 \end{bmatrix}\end{aligned}\quad (4)$$

- (b) Seja σ_d^2 a variância do sinal desejado, o mínimo erro médio quadrático fornecido pelo filtro de Wiener é [1]

$$\begin{aligned} J_{min} &= \sigma_d^2 - \mathbf{R}_{dx}^H \mathbf{w}_o \\ J_{min} &= \sigma_d^2 - 0.25 \end{aligned} \quad (5)$$

- (c) Uma expressão importante obtida a partir do filtro de Wiener é o valor da função de custo em torno do ponto ótimo, que pode ser expressada em termos dos autovalores e autovetores da matriz \mathbf{R}_x . Considere o sinal de erro da saída de um filtro de FIR cujos os coeficiente não minimizam a função custo (i.e., filtro não-ótimo, $\mathbf{w} \neq \mathbf{w}_o$), o erro quadrático é

$$\begin{aligned} |e[n]|^2 &= (d[n] - \mathbf{w}^H \mathbf{x}) (d[n] - \mathbf{w}^H \mathbf{x})^H \\ &= (d[n] - \mathbf{w}^H \mathbf{x}) (d[n] - \mathbf{x}^H \mathbf{w}) \\ &= |d[n]|^2 - d[n] \mathbf{x}^H \mathbf{w} - d[n] \mathbf{w}^H \mathbf{x} + \mathbf{w}^H \mathbf{x} \mathbf{x}^H \mathbf{w} \end{aligned} \quad (6)$$

Calculando a média na equação (6) e observando que $\mathbf{w}^H \mathbf{x} = \mathbf{x}^H \mathbf{w}$, têm-se:

$$\begin{aligned} J(\mathbf{w}) &\triangleq E[|e[n]|^2] \\ &= E[|d[n]|^2 - d[n] \mathbf{x}^H \mathbf{w} - d[n] \mathbf{w}^H \mathbf{x} + \mathbf{w}^H \mathbf{x} \mathbf{x}^H \mathbf{w}] \\ &= \sigma_d^2 - 2\mathbf{w}^H \mathbf{R}_{dx} + \mathbf{w}^H \mathbf{R}_x \mathbf{w} \end{aligned} \quad (7)$$

Observe que se substituirmos (4) em (7), obteremos a equação (5), ou seja, $J_{min} = J(\mathbf{w}_o)$. Pode-se analisar como a função custo se comporta em torno do ponto ótimo fazendo com que $\mathbf{w} = \mathbf{w}_o + \Delta \mathbf{w}$, então

$$\begin{aligned} J(\mathbf{w}_o + \Delta \mathbf{w}) &= \sigma_d^2 - 2(\mathbf{w}_o + \Delta \mathbf{w})^H \mathbf{R}_{dx} + (\mathbf{w}_o + \Delta \mathbf{w})^H \mathbf{R}_x (\mathbf{w}_o + \Delta \mathbf{w}) \\ &= J_{min} + \Delta \mathbf{w}^H \mathbf{R}_x \Delta \mathbf{w} \end{aligned} \quad (8)$$

A matriz \mathbf{R}_x pode ser diagonalizada em termos da matriz modal (i.e., a matriz formada pelos autovetores) e a matriz diagonal dos autovalores [2].

$$\mathbf{R}_x = \mathbf{Q}^H \mathbf{\Lambda} \mathbf{Q} \quad (9)$$

Em que \mathbf{Q} é a matriz modal

$$\mathbf{Q} = \begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 \end{bmatrix}$$

$$\mathbf{Q} = \begin{bmatrix} -0.7071 & 0.7071 \\ 0.7071 & 0.7071 \end{bmatrix} \quad (10)$$

E $\mathbf{\Lambda}$ é matriz diagonal formada pelos autovalores [2]

$$\mathbf{\Lambda} = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \quad (11)$$

$$\mathbf{\Lambda} = \begin{bmatrix} 0.5 & 0 \\ 0 & 1.5 \end{bmatrix} \quad (12)$$

Substituindo (9) em (8), temos:

$$J(\mathbf{w}_o + \Delta \mathbf{w}) = J_{min} + \Delta \mathbf{w}^H \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^H \Delta \mathbf{w} \quad (13)$$

$$= J_{min} + \mathbf{v}^H \mathbf{\Lambda} \mathbf{v} \quad (14)$$

Em que $\mathbf{v} = \mathbf{Q}^H \Delta \mathbf{w}$.

2. Considere a seguinte representação matricial da equação de Wiener–Hopf e da equação da função de custo mínima (mostradas em (4) e (5), respectivamente):

$$\begin{bmatrix} \sigma_d^2 & \mathbf{R}_{dx}^H \\ \mathbf{R}_{dx} & \mathbf{R}_x \end{bmatrix} \begin{bmatrix} 1 \\ -\mathbf{w}_o \end{bmatrix} = \begin{bmatrix} J_{min} \\ \mathbf{0} \end{bmatrix}$$

$$\mathbf{A} \begin{bmatrix} 1 \\ -\mathbf{w}_o \end{bmatrix} = \begin{bmatrix} J_{min} \\ \mathbf{0} \end{bmatrix} \quad (15)$$

Em que $\mathbf{0}$ é o vetor nulo com dimensão igual a ordem do filtro de Wiener–Hopf. Com base na equação (15), pode-se facilmente concluir que \mathbf{A} é matriz de correlação do vetor aumentado

$$\begin{bmatrix} d[n] \\ \mathbf{x} \end{bmatrix} \quad (16)$$

Nesta análise, estamos supondo que $d[n]$ possui média nula e, portanto, o segundo momento central é igual ao seu segundo momento, i.e., $\sigma_d^2 \triangleq E[(d[n] - E[d[n]])^2] = E[d^2[n]]$.

3. A Figura 1 mostra um diagrama de blocos de uma arquitetura típica de cancelamento de ruído.

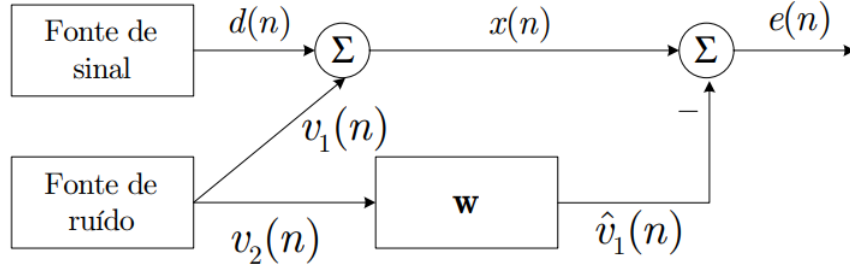


Figura 1: Cancelamento de ruído

Cancelamento de ruído é um assunto clássico em sistemas de comunicações no qual se pode utilizar técnicas de processamento estatístico de sinais para estimar o ruído incidente no sinal transmitido e, por fim, suprimi-lo [3].

Neste tipo de problema, é utilizado dois sensores. Enquanto o primeiro capta o sinal transmitido corrompido pelo ruído (representado na Figura 1 como $x[n]$), o segundo sensor capta apenas o ruído do canal (representado como $v_2[n]$). Portanto, os sinais conhecidos para este problema são $v_2[n]$ e $x[n]$.

No entanto, a subtração direta do sinal $v_2[n]$ no sinal recebido não fornece o desempenho desejado, pois, apesar de se originarem da mesma fonte, o ruído captado pelo segundo sensor ($v_2[n]$) é um processo estocástico diferente do ruído que é captado pelo primeiro sensor ($v_1[n]$). Apesar de ambos guardarem uma certa correlação, seus valores para o mesmo instante de amostragem se diferem. Afinal, tratam-se de processos estocásticos, e não determinísticos.

O problema então é: Com base no ruído do segundo sensor ($v_2[n]$), estimar, através da implementação de um filtro de Wiener, a estimativa do ruído que distorce o sinal desejado ($\hat{v}_1[n]$) [3], [4].

O objetivo do filtro de Wiener é selecionar os coeficiente do filtro FIR de tal forma de minimize a função custo, ou seja:

$$\begin{aligned}
 \frac{\partial}{\partial \mathbf{w}} E \{e[n]e^*[n]\} &= 0 \\
 E \left\{ e[n] \frac{\partial e^*[n]}{\partial \mathbf{w}} \right\} &= 0 \\
 E \left\{ e[n] \frac{\partial (x^*[n] - \hat{v}_1^*[n])}{\partial \mathbf{w}} \right\} &= 0 \\
 E \left\{ e[n] \frac{\partial (x^*[n] - \mathbf{w}^T \mathbf{v}_2^*)}{\partial \mathbf{w}} \right\} &= 0 \\
 E \{e[n]\mathbf{v}_2^*\} &= \mathbf{0}
 \end{aligned} \tag{17}$$

Em que $\mathbf{v}_2 = \begin{bmatrix} v_2[n] & v_2[n-1] & \cdots & v_2[n-M+1] \end{bmatrix}^T$, M é a ordem do filtro de Wiener e $\mathbf{0}$ é vetor nulo de ordem M . Portanto:

$$E \{e[n]v_2^*[n-k]\} = 0 \text{ para } 0 \leq k \leq M-1 \quad (18)$$

Essa equação fornece que, quando o filtro é ótimo, o erro é ortogonal ao sinal de entrada. Substituindo o sinal de erro, têm-se:

$$\begin{aligned} E \{ (x[n] - \hat{v}_1[n]) v_2^*[n-k] \} &= 0 \\ E \left\{ \left(x[n] - \sum_{i=1}^{M-1} w[i] v_2[n-i] \right) v_2^*[n-k] \right\} &= 0 \\ E \left\{ x[n] v_2^*[n-k] - \sum_{i=1}^{M-1} w[i] v_2[n-i] v_2^*[n-k] \right\} &= 0 \\ E \{ x[n] v_2^*[n-k] \} - \sum_{i=1}^{M-1} w[i] E \{ v_2[n-i] v_2^*[n-k] \} &= 0 \end{aligned} \quad (19)$$

Com base na Figura 1, pode-se ainda deixar o sinal recebido ($x[n]$) em termos do ruído e do sinal transmitido:

$$\begin{aligned} E \{ (d[n] + v_1) v_2^*[n-k] \} &= \sum_{i=1}^{M-1} w[i] E \{ v_2[n-i] v_2^*[n-k] \} \\ E \{ d[n] v_2^*[n-k] \} + E \{ v_1[n] v_2^*[n-k] \} &= \sum_{i=1}^{M-1} w[i] E \{ v_2[n-i] v_2^*[n-k] \} \\ R_{d,v_2}[k] + R_{v_1,v_2}[k] &= \sum_{i=1}^{M-1} w[i] R_{v_2,v_2}[k-i] \end{aligned} \quad (20)$$

Observe que o sinal desejado, $d[n]$ e o ruído do segundo sensor, $v_2[n]$, são descorrelacionados, portanto

$$R_{d,v_2}[k] = 0, \forall k \in \mathbb{Z} \quad (21)$$

Por outro lado, os processos estocásticos $v_1[n]$ e $v_2[n]$ guardam algum tipo de correlação, pois ambos se originam da mesma fonte. A expressão analítica da função de correlação cruzada que estes dois sinais possuem varia para cada aplicação. A função de autocorrelação de $v_2[n]$ seria, no caso mais descorrelacionado possível, AWGN (do inglês, *Additive white Gaussian noise*), i.e., suas amostras teriam correlação nula em diferenças de instantes diferentes de zero. É importante ressaltar que estamos a considerar que os processos aleatórios envolvidos neste problema são WSS (*Wide Sense Stationary*) e, portanto, considerar-se apenas a diferença entre

as amostras uma vez que o deslocamento temporal das mesmas não afeta a função de autocorrelação.

No entanto, o não é possível calcular $R_{v_1, v_2}[k]$ uma vez que o sinal $v_1[n]$ não é conhecido. Felizmente, é fácil mostrar que

$$\begin{aligned}
R_{v_1, v_2}[k] &= E \{v_1[n-i]v_2^*[n-k]\} \\
R_{v_1, v_2}[k] &= E \{(x[n] - d[n])v_2^*[n-k]\} \\
R_{v_1, v_2}[k] &= E \{x[n]v_2^*[n-k]\} - E \{d[n]v_2^*[n-k]\} \\
R_{v_1, v_2}[k] &= R_{x, v_2}[k] - R_{d, v_2}[k] \\
R_{v_1, v_2}[k] &= R_{x, v_2}[k]
\end{aligned} \tag{22}$$

Substituindo (21) e (22) em (20), têm-se:

$$\sum_{i=1}^{M-1} w[i] R_{v_2, v_2}[k-i] = R_{x, v_2}[k] \tag{23}$$

Ou, em notação matricial:

$$\begin{aligned}
\mathbf{R}_{\mathbf{v}_2, \mathbf{v}_2} \mathbf{w} &= \mathbf{R}_{\mathbf{x}, \mathbf{v}_2} \\
\mathbf{w} &= \mathbf{R}_{\mathbf{v}_2, \mathbf{v}_2}^{-1} \mathbf{R}_{\mathbf{x}, \mathbf{v}_2}
\end{aligned} \tag{24}$$

Considera-se que $\mathbf{R}_{\mathbf{v}_2, \mathbf{v}_2}$ possua inversa. O resultado obtido em (24) é exatamente a equação de Wiener-Hopf (ver equação (4)), mas derivado do estudo sobre cancelamento de ruído.

4. A Figura 2 mostra a estrutura típica de uma *Forward Linear Prediction* (FLP) *one-step* [1] [4].

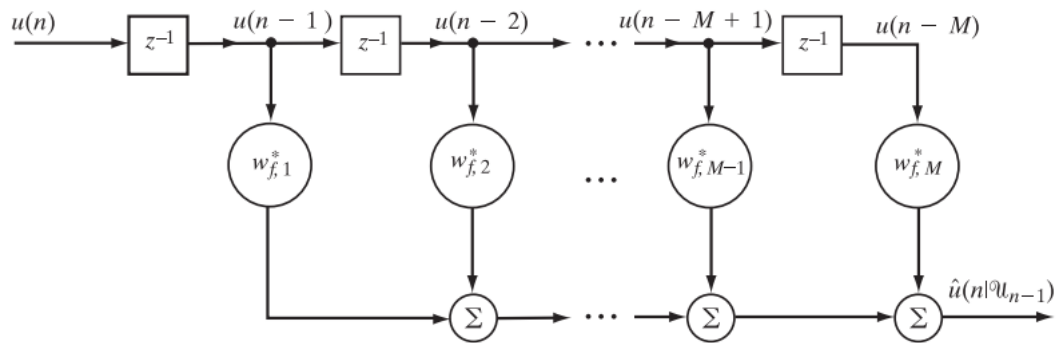


Figura 2: *Forward Linear Prediction* (FLP) *one-step*.

A otimização do erro quadrático médio também é obtido por meio da implementação

do filtro de Wiener. Portanto, todas as equações provenientes do seu estudo são utilizadas na predição linear.

A abordagem clássica fornecida na literatura sobre *Forward Linear Prediction* (FLP) *one-step* é [1]: Dado um vetor de variáveis aleatórias

$$\mathbf{u}[n-1] = \begin{bmatrix} u[n-1] & u[n-2] & \cdots & u[n-M+1] \end{bmatrix}^T,$$

predizer o valor da próxima amostra, $u[n]$ (por este motivo que é chamado de *one-step*).

No entanto, neste problema, o sinal de entrada é $x[n] = s[n+a] + s[n-4a]$. Além disso, não se deseja a próxima amostra, mas sim de $d[n] = s[n-a]$. Da equação de Wiener em (4), temos:

$$\mathbf{w}_f = \mathbf{R}_x^{-1} \mathbf{r}_{x,s} \quad (25)$$

Em que \mathbf{R}_x é a matriz correlação do sinal de entrada, dado por

$$\mathbf{R}_x = \begin{bmatrix} R_x(0) & R_x(1) \\ R_x(-1) & R_x(0) \end{bmatrix} \quad (26)$$

e $\mathbf{r}_{x,s}$ é a matriz de correlação cruzada entre o sinal de entrada e o sinal desejado, ou seja:

$$\mathbf{r}_{x,s} = \begin{bmatrix} R_{x,s}(0) \\ R_{x,s}(1) \end{bmatrix} \quad (27)$$

A função de auto correlação do sinal $x[n]$ é:

$$\begin{aligned} R_x(\tau) &= E[x[n]x[n-\tau]] \\ &= E[(s[n+a] + s[n-4a])(s[n+a-\tau] + s[n-4a-\tau])] \\ &= 2R_s(\tau) + R_s(\tau+5a) + R_s(\tau-5a) \end{aligned} \quad (28)$$

E a função de correlação cruzada é:

$$\begin{aligned} R_{x,s}(\tau) &= E[x[n]s[n-a-\tau]] \\ R_{x,s}(\tau) &= E[(s[n+a] + s[n-4a])s[n-a-\tau]] \\ R_{x,s}(\tau) &= R_s(\tau+2a) + R_s(\tau-3a) \end{aligned} \quad (29)$$

Substituindo (26) e (27) em (25), têm-se

$$\begin{aligned}\mathbf{w}_f &= \frac{1}{|\mathbf{R}_x|} \begin{bmatrix} R_x(0)R_{x,s}(0) - R_x(1)R_{x,s}(1) \\ -R_x(-1)R_{x,s}(0) + R_x(0)R_{x,s}(1) \end{bmatrix} \\ &= \frac{1}{|\mathbf{R}_x|} \begin{bmatrix} \mathbf{w}_{f1} \\ \mathbf{w}_{f2} \end{bmatrix}\end{aligned}\quad (30)$$

Em que

$$\begin{aligned}\mathbf{w}_{f1} &= (R_s(2a) + R_s(-3a)) (2R_s(5a) + 2) \\ &\quad - (R_s(2a + 1) + R_s(1 - 3a)) (2R_s(1) + R_s(1 - 5a) + R_s(5a + 1))\end{aligned}\quad (31)$$

e

$$\begin{aligned}\mathbf{w}_{f2} &= (R_s(2a + 1) + R_s(1 - 3a)) (2R_s(5a) + 2) \\ &\quad - (R_s(2a) + R_s(-3a)) (2R_s(-1) + R_s(-5a - 1) + R_s(5a - 1))\end{aligned}\quad (32)$$

Para essas simplificações, utilizamos as seguintes propriedades de processos aleatórios WSS [5]:

- $R_s(\tau)$ é uma função par, i.e., $R_s(\tau) = R_s(-\tau)$
- $R_s(0) = E[s^2[n]] = \text{VAR}[s[n]] = 1$. Lembre-se que $E[s[n]] = 0$.

Infelizmente, não é possível simplificar mais as equações (31) e (32) pois $s[n]$ não é uma sequência de variáveis aleatórias independentes, portanto $E[s[n]s[n - \tau]] \neq E[s[n]]E[s[n - \tau]]$

5. (a) A matriz de correlação do sinal de entrada é dada por

$$\mathbf{R}_x = \begin{bmatrix} R_x(0) & R_x(1) \\ R_x(-1) & R_x(0) \end{bmatrix}\quad (33)$$

Em que $R_x(0) = 1$ e $R_x(1) = R_x(-1) = 0$. Portanto, temos

$$\mathbf{R}_x = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\quad (34)$$

Note que esta matriz de correlação é uma matriz identidade. Logo $\mathbf{R}_x^{-1} = \mathbf{R}_x$. A matriz de correlação cruzada é

$$\mathbf{R}_{dx} = \begin{bmatrix} 2 \\ 4.5 \end{bmatrix}\quad (35)$$

Substituindo as equações (34) (35) em (4), temos

$$\mathbf{w}_o = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 4.5 \end{bmatrix} \quad (36)$$

- (b) A equação (7) fornece uma expressão para a superfície da função custo em termos dos parâmetros do filtro ótimo (ou filtro de Wiener). Substituindo os valores dessa questão na equação referenciada, têm-se

$$\begin{aligned} J(\mathbf{w}) &= \sigma_d^2 - 2\mathbf{w}^H \mathbf{R}_{dx} + \mathbf{w}^H \mathbf{R}_x \mathbf{w} \\ &= w_1 w_1^* - 9 w_2^* - 4 w_1^* + w_2 w_2^* + \frac{122}{5} \\ &= w_1^2 - 9 w_2 - 4 w_1 + w_2^2 + \frac{122}{5} \end{aligned} \quad (37)$$

Em que x^* indica o conjugado de x . Considera-se que os coeficientes do filtro sejam reais. A Figura 3 mostra a função de custo em termos dos coeficientes w_1 e w_2 . O ponto em vermelho destacado refere-se ao ponto de Wiener, \mathbf{w}_o .

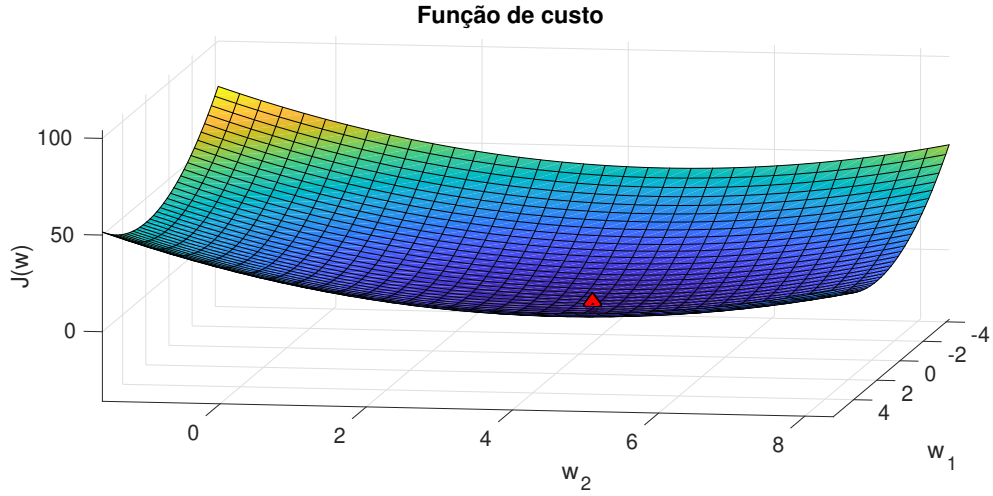


Figura 3: Função custo.

Pode-se observar que os coeficientes de filtro ótimo, de fato, minimizam o erro quadrático médio da função ($J(\mathbf{w}_o) = 0.15$).

Referências

- [1] S. Haykin, *Adaptive Filter Theory*. Pearson, 5nd ed., 2014.
- [2] M. Barkat, *Signal Detection And Estimation (Artech House Radar Library)*. Artech House Publishers, 2nd ed., 2005.

- [3] J. G. P. M. Salehi, *Digital communications*. McGraw-Hill higher education, McGraw-Hill, 5th ed ed., 2008.
- [4] S. abrant, *Processamento Adaptativo de Sinais*. Fundação Calouste Gulbekian, 2000.
- [5] A. Leon-Garcia, *Probability, Statistics, and Random Processes For Electrical Engineering, 3rd Edition*. Prentice Hall, the 3rd edition ed., 2008.