

# ADAPTIVE LINEAR ELEMENT (ADALINE)

**Prof. Dr. Ajalmar Rocha**

**Disciplina: Inteligência Computacional Aplicada (ICA)**

Programa de Pós-Graduação em Eng. de Telecomunicações (PPGET)  
Instituto Federal do Ceará (IFCE)

Agosto/2013

# Resumo

- Introdução
- ADALINE
- Função Quadrática de Erro
- Minimização da Função Custo
- Gradiente da Função Custo
- Regra de Aprendizagem

# Introdução

- O objetivo do processo de aprendizado de uma rede neural é estimar uma função  $F : \mathbb{R}^{p+1} \rightarrow \mathbb{R}$  usando um conjunto:

$$(\mathbf{x}_1, d_1), \dots, (\mathbf{x}_n, d_n) \in \mathbb{R}^{p+1} \times \mathbb{R} \quad (1)$$

em que  $\mathbf{x}_i$  é o  $i$ -ésimo padrão de entrada (ou vetor de entrada) e  $d_i$  é a saída desejada.


- Este conjunto pode ser apresentado de forma concisa, tal como:

$$\{(\mathbf{x}_i, d_i)\}_{i=1}^N. \quad (2)$$

- Ressalta-se que o mapeamento  $F(\cdot)$  para um vetor de entrada não especificado é completamente desconhecido, sendo a sua determinação o objetivo do treinamento das redes neurais.

# Introdução

- Nesse contexto, um mapeamento  $F(.)$  pode ser representado de forma simplificada como:



- E, portanto, uma rede neural pode ser utilizada para a obtenção de um mapeamento aproximado para o conjunto de dados  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ , i.e.,  $\hat{F}(.)$ . Portanto, a saída estimada  $\hat{d}$ , pode ser descrita por  $y = \hat{d} = \hat{F}(\mathbf{x})$ .

# Introdução

- E, portanto, uma rede neural pode ser utilizada para a obtenção de um mapeamento aproximado para o conjunto de dados  $\{(\mathbf{x}_i, d_i)\}_{i=1}^N$ , i.e.,  $\hat{F}(\cdot)$ . Assim, a saída estimada  $\hat{d} = y$  pela rede neural, tal que:

$$y = \hat{F}(\mathbf{x}). \quad (3)$$

- O processo que permite a descoberta de leis gerais pela observação e combinação de exemplos particulares é chamado **aprendizado indutivo**.

# ADALINE

- Em 1960, o Elemento Linear Adaptativo (*Adaptive Linear Element* - ADALINE) surgiu na literatura quase que simultaneamente com o Perceptron, no trabalho:

Widrow and Hoff (1960)

**B. Widrow and M. E. Hoff.** Adaptive switching circuits. In IRE WESCON Convention Record-Part 4, pages 96-104, 1960.

- Ambos os modelos são baseados em elementos de processamento que executam operações sobre soma ponderada de suas entradas.
- A operação é não-linear do tipo degrau para o Perceptron.
- Enquanto, a operação é puramente linear para o ADALINE.

# ADALINE

- Outros trabalhos relacionados ao ADALINE são apresentados a seguir.

**B. Widrow and S. D. Stearns.** Adaptive Signal Processing. Prentice-Hall, Upper Saddle River, NJ, 1985.

**B. Widrow and R. Winter.** Neural nets for adaptive filtering and adaptive pattern recognition. IEEE Computer, 21(3):25-39, 1988.

**B. Widrow and M.A. Lehr.** 30 years of adaptive neural networks: Perceptron, madaline and backpropagation. In Proceedings of the IEEE, volume 78, pages 1415-1442, 1990.

# Neurônio Artificial para ADALINE

- Como dito, um neurônio artificial possui  $p$  entradas  $\{x_i\}_{i=1}^p$  e possui  $p$  pesos sinápticos  $\{w_i\}_{i=1}^p$ , bem como um limiar (threshold) de ativação  $\theta$ .
- O neurônio possui uma variável de ativação  $u$ , tal que

$$u = x_1 w_1 + x_2 w_2 + \cdots - \theta = \sum_{i=1}^p x_i w_i - \theta. \quad (4)$$

- Enquanto, a variável de saída para o ADALINE é descrita como segue:

$$y = f(u) = u. \quad (5)$$



# Neurônio Artificial para ADALINE


- Na equação para o cálculo da variável de saídas

$$y = f(u) = u = \mathbf{w}^T \mathbf{x} = \mathbf{x}^T \mathbf{w} = \sum_{i=0}^p w_i x_i. \quad (6)$$

o vetor de pesos  $\mathbf{w}$  e de entrada  $\mathbf{x}$  é descrito por

$$\mathbf{w} = \begin{bmatrix} \theta \\ w_1 \\ w_2 \\ \dots \\ w_p \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \dots \\ x_p \end{bmatrix}$$

# Arquitetura para ADALINE



## Função Quadrática de Erro

- O erro obtido com base na variável de saída e na saída desejada para um dado padrão  $(\mathbf{x}_i, d_i)$  é descrito por:

$$e = d_i - y = d_i - u. \quad (7)$$

- O erro quadrático instantâneo para um dado vetor de entrada  $(\mathbf{x}_i, d_i)$  é dado pela Equação (8)

$$\begin{aligned} e^2 &= (d_i - y)^2 \\ e^2 &= (d_i - \mathbf{w}^T \mathbf{x}_i)^2 \\ e^2 &= d_i^2 - 2d_i \mathbf{w}^T \mathbf{x}_i + (\mathbf{w}^T \mathbf{x}_i)^2, \end{aligned} \quad (8)$$

a qual contém um termo quadrático em  $\mathbf{w}$  e, por conseguinte, resulta em uma superfície em forma de parábola.

# Minimização da Função Custo

- Considerando o erro quadrático como critério de desempenho, a partir de um valor inicial para o vetor de pesos, objetiva-se que o vetor de pesos se aproxime gradativamente do mínimo global.
- No entanto, busca-se atingir o mínimo da superfície  $J$  resultante, a saber:

$$J = \frac{1}{2}e^2$$

$$J = \frac{1}{2}(d_i - y)^2$$

$$J = \frac{1}{2}(d_i - u)^2$$

$$J = \frac{1}{2}(d_i - \mathbf{w}^T \mathbf{x}_i)^2 \quad (9)$$

# Minimização da Função Custo

- Com o intuito de minimizar a função custo

$$J = \frac{1}{2}(d_i - \mathbf{w}^T \mathbf{x}_i)^2$$

é necessário que seja obtido a direção do ajuste a ser aplicado no vetor de pesos para aproximar a solução do mínimo de  $J$ .

- Para tal, usa-se o gradiente da função custo  $J$  no ponto  $\mathbf{w}(t)$ .
- Sabe-se que o gradiente possui a mesma direção da maior variação do erro (aponta na direção de crescimento da função), portanto o ajuste deve ocorrer na direção contrária ao gradiente. Logo, a variação dos pesos pode ser descrita por:

$$\Delta \mathbf{w}(t) \propto -\nabla J. \quad (10)$$

# Gradiente da Função Custo

## Consideração

Sabe-se que a função custo  $J$  depende de  $e$ , bem como sabe-se que  $e$  depende de  $y$ , e ainda sabe-se que  $y$  depende de  $\mathbf{w}$ .

- Cada componente do gradiente da função custo  $\nabla J$  pode ser obtida com base na regra da cadeia, a saber:

$$\frac{\partial J}{\partial w_i} = \frac{\partial J}{\partial e} \frac{\partial e}{\partial u} \frac{\partial u}{\partial w_i} \quad (11)$$

- Sabendo ainda que

$$\frac{\partial J}{\partial e} = e, \quad \frac{\partial e}{\partial u} = -1 \quad \text{and} \quad \frac{\partial u}{\partial w_i} = x_i,$$

# Gradiente da Função Custo

- Logo a  $i$ -ésima componente do gradiente da função custo

$$\frac{\partial J}{\partial w_i} = \frac{\partial J}{\partial e} \frac{\partial e}{\partial u} \frac{\partial u}{\partial w_i} \quad (12)$$

considerando que

$$\frac{\partial J}{\partial e} = e, \quad \frac{\partial e}{\partial u} = -1 \quad \text{and} \quad \frac{\partial u}{\partial w_i} = x_i,$$

é igual a

$$\begin{aligned} \frac{\partial J}{\partial w_i} &= -x_i e \\ \frac{\partial J}{\partial \mathbf{w}} &= -\mathbf{x} e \end{aligned} \quad (13)$$

# Regra de Aprendizagem

- A regra de aprendizagem pode então ser obtida como segue.

$$\begin{aligned}\Delta \mathbf{w} &= \mathbf{w}(t+1) - \mathbf{w}(t) \\ \mathbf{w}(t+1) &= \mathbf{w}(t) + \Delta \mathbf{w}\end{aligned}\tag{14}$$

- Considerando que  $\Delta \mathbf{w}(t) \propto -\nabla J$ , pode se escrever


$$\begin{aligned}\Delta \mathbf{w} &= \mathbf{w}(t+1) - \mathbf{w}(t) \\ \mathbf{w}(t+1) &= \mathbf{w}(t) + \Delta \mathbf{w} \\ \mathbf{w}(t+1) &= \mathbf{w}(t) - \eta \nabla J\end{aligned}\tag{15}$$

- Além disto, sabendo que  $\frac{\partial J}{\partial \mathbf{w}} = -\mathbf{x}e$  temos que


$$\mathbf{w}(t+1) = \mathbf{w}(t) + \eta e(t) \mathbf{x}(t)\tag{16}$$



# Superfície de Erro



# Curvas de Nível para Otimização dos Pesos



## Diferença entre o Perceptron e o ADALINE

- **Qual a principal diferença entre os modelos Perceptron e ADALINE?**
- O Perceptron é um separador linear, enquanto o ADALINE é um aproximador linear de funções.
- Assim, os modelos se aplicam a problemas de natureza diferente.
- O Perceptron é aplicado em problemas de classificação de padrões; enquanto o ADALINE em problemas de aproximação de funções.
- **Seria possível usar o ADALINE para classificação de padrões? ou o Perceptron para aproximação de funções?**

OBRIGADO